

Evaluación controlada de OpenCLIP para recuperación de texto a imagen sobre patrones textiles sintéticos

Henry Sánchez Alvarado

MCC225: IA Generativa y Aprendizaje Multimodal – Universidad Nacional de Ingeniería

Repositorio:

<https://github.com/hsancheza90-art/mcc225-textiles-generados-evaluacion-multimodal>

Versión evaluada: `mcc225-examen-final-v2.1`

Commit del release auditado: `5de136ca1fc438a0ec5425988dfab404a993eafe`

Integración final en main: `9a5a82d9f16f2eec84917de6f8e14097fc90e279`

Resumen

Este trabajo evalúa OpenCLIP ViT-B-32, en régimen *zero-shot* y sin ajuste fino, en una tarea controlada de recuperación de texto a imagen. El benchmark contiene 56 imágenes sintéticas formadas por combinaciones únicas de ocho patrones geométricos y siete paletas, junto con 280 captions positivos. La evaluación separa recuperación exacta, elección forzada ante negativos difíciles y recuperación estructural con múltiples imágenes relevantes. OpenCLIP obtuvo Recall@1 de 0,236, Recall@5 de 0,825, MRR de 0,462 y nDCG@10 de 0,581, superando al baseline aleatorio y al histograma HSV. En la prueba con cuatro negativos difíciles por imagen alcanzó una exactitud de 0,518 y una tasa de victorias pareadas de 0,835. La conversión de las imágenes a escala de grises redujo el Recall@1 exacto a 0,086, lo que muestra que el color aporta información relevante para identificar la combinación exacta. En cambio, al definir la relevancia por estructura compartida, retirar el color favoreció algunas métricas, sin constituir una mejora universal. Los resultados describen alineamiento multimodal dentro de un entorno sintético y no permiten afirmar reconocimiento cultural, autenticación patrimonial ni generalización a textiles reales.

Palabras clave: recuperación multimodal; OpenCLIP; texto a imagen; patrones sintéticos; negativos difíciles; ablaciones; evaluación responsable.

1. Introducción

Los modelos visión-lenguaje representan imágenes y textos en un espacio de embeddings compartido, lo que permite ordenar una galería visual a partir de una consulta textual. CLIP popularizó este enfoque mediante aprendizaje contrastivo a gran escala (Radford et al., 2021); OpenCLIP ofrece una implementación abierta y reproducible de esta familia de modelos (Cherti et al., 2023).

Este trabajo estudia una pregunta acotada: si un modelo preentrenado puede relacionar captions controlados en español con patrones geométricos sintéticos que varían en motivo, orientación, composición, simetría y paleta. La evaluación se centra en recuperación multimodal, no en clasificación cultural ni en interpretación simbólica.

1.1. Pregunta experimental

¿En qué medida OpenCLIP ViT-B-32, utilizado en régimen *zero-shot* y sin ajuste fino, puede recuperar la imagen correcta a partir de captions controlados que describen patrones textiles sintéticos, y qué revelan los baselines, los negativos difíciles y las ablaciones cromáticas sobre la contribución del color y de la estructura visual a su desempeño?

1.2. Objetivo general

Evaluar de manera controlada, reproducible y responsable el desempeño de OpenCLIP ViT-B-32 en una tarea de recuperación de texto a imagen sobre un benchmark sintético de patrones textiles, analizando correspondencias exactas, discriminación ante descripciones contrafactuales e información visual más allá de la paleta.

1.3. Objetivos específicos

1. Construir y auditar un benchmark de combinaciones visuales únicas con captions positivos basados en atributos observables.
2. Evaluar OpenCLIP mediante Recall@1, Recall@5, MRR y nDCG@10.
3. Comparar el modelo con baselines aleatorio y HSV.
4. Analizar negativos difíciles y ablaciones cromáticas exactas y estructurales.

5. Examinar descriptivamente las particiones sintéticas ID y OOD.
6. Documentar reproducibilidad, limitaciones y uso responsable.

Alcance. Este trabajo evalúa alineamiento multimodal dentro de un benchmark sintético controlado. No identifica culturas, no autentica piezas, no infiere procedencia y no demuestra generalización a textiles reales.

2. Fundamentos de recuperación multimodal

2.1. Dual encoders y similitud

OpenCLIP codifica imagen y texto mediante encoders separados. Sean $\mathbf{v}_i$ y $\mathbf{t}_j$ embeddings normalizados mediante norma L2. La similitud empleada en el proyecto es:

$$s(i, j) = \mathbf{v}_i^\top \mathbf{t}_j, \quad (1)$$

que equivale a la similitud coseno cuando ambos vectores tienen norma unitaria. El ranking se obtiene ordenando la galería en forma descendente según equation (1).

2.2. Relación con los contenidos de MCC225

El proyecto integra varios conceptos centrales desarrollados en MCC225. En primer lugar, las imágenes y los captions se representan mediante *embeddings* dentro de un espacio vectorial compartido. Esta representación permite comparar modalidades diferentes mediante una medida de similitud y construir un ranking de imágenes para cada consulta textual.

OpenCLIP emplea una arquitectura de tipo *dual encoder*: el encoder visual y el encoder textual procesan sus entradas de manera independiente. La interacción entre ambas modalidades ocurre posteriormente, al calcular la similitud entre sus embeddings normalizados. Esta arquitectura permite realizar recuperación cruzada de texto a imagen de manera eficiente, aunque puede limitar la representación de interacciones composicionales finas entre atributos visuales y lingüísticos.

El modelo se evalúa en régimen *zero-shot* y sin ajuste fino. Por tanto, el experimento mide la utilidad de una representación visión-lenguaje preentrenada frente a un benchmark nuevo, sin adaptar sus parámetros a las imágenes sintéticas ni a los captions del proyecto.

Los negativos difíciles se relacionan con el estudio de la discriminación multimodal. Cada negativo conserva cuatro atributos y modifica solamente uno, lo que permite observar si la similitud responde a cambios controlados de paleta, motivo, orientación, composición o simetría. Las ablaciones, por su parte, permiten estudiar la contribución del color y de la estructura al resultado del retrieval.

En este trabajo, el *grounding* se limita a atributos observables de las imágenes: color, formas geométricas, orientación, distribución y simetría. No se evalúa grounding cultural, histórico o simbólico. Finalmente, el uso de semillas, configuraciones congeladas, hashes, tablas maestras y validadores relaciona la implementación con los principios de reproducibilidad y evaluación responsable abordados en el curso.

2.3. Métricas

En recuperación exacta existe una imagen relevante por consulta. Recall@1 indica si aparece en la primera posición y Recall@5 si se encuentra entre las cinco primeras. MRR resume la posición del primer relevante:

$$\text{MRR} = \frac{1}{N} \sum_{q=1}^N \frac{1}{r_q}, \quad (2)$$

con r_q igual al rango de la primera respuesta relevante. nDCG@10 pondera la calidad del ranking temprano y resulta útil cuando existen múltiples relevantes (Järvelin & Kekäläinen, 2002). En el protocolo estructural se distinguen Hit@K y recall fraccional@5, porque cada consulta posee siete imágenes relevantes.

3. Diseño experimental

3.1. Dataset sintético v2

El benchmark contiene 56 imágenes de 512×512 píxeles, ocho patrones y siete paletas. Cada par patrón-paleta aparece una sola vez. Las particiones se definieron antes de generar las imágenes y representan controles sintéticos.

Cuadro 1: Distribución del dataset v2.

Partición	Imágenes	Definición
ID	30	Patrones base con paletas base.
OOD por paleta	12	Patrones base con paletas reservadas.
OOD por patrón	10	Patrones reservados con paletas base.
OOD combinado	4	Patrones y paletas reservados.
Total	56	56 pares patrón–paleta únicos.

3.2. Captions positivos, control léxico y negativos difíciles

Cada imagen posee cinco captions positivos completos, para un total de 280 consultas textuales. Cada caption expresa cinco atributos visuales observables: paleta, motivo, orientación, composición y simetría. Las mismas cinco plantillas se aplican a las 56 firmas semánticas, de modo que cada plantilla aparece exactamente 56 veces y no identifica por sí sola una imagen, un patrón o una partición.

Este diseño reduce los atajos asociados con una estructura sintáctica exclusiva. Sin embargo, no elimina todos los posibles atajos léxicos: términos explícitos como el nombre de una paleta, “círculos”, “horizontal” o “reticular” pueden aportar señales directas sobre la respuesta. Por ello, el protocolo combina tres controles complementarios: candidatos escritos con la misma plantilla, negativos que modifican un único atributo y ablaciones que retiran la información cromática de la imagen o del texto.

La evaluación de negativos difíciles utiliza cada una de las 56 imágenes como unidad de consulta. Para cada imagen se construye un conjunto de cinco captions candidatos: uno positivo y cuatro negativos contrafactuales. Todos emplean la plantilla canónica TPL_01; por tanto, comparten estructura sintáctica y difieren únicamente en los valores de los atributos. Cada negativo cambia exactamente uno de los siguientes elementos y conserva los otros cuatro: paleta, motivo, orientación, composición o simetría.

El nivel de azar en esta elección forzada es:

$$p_{\text{azar}} = \frac{1}{5} = 0,20.$$

Como existen cinco atributos y solo cuatro negativos por consulta, el atributo omitido rota de manera determinista. En el conjunto completo, cada tipo de modificación aparece 44 o 45 veces, lo que mantiene una distribución aproximadamente balanceada.

La etiqueta negativa es local a la imagen consultada. Un caption contrafactual puede describir correctamente otra imagen de la galería, especialmente cuando solo cambia la paleta. Por ello, estos textos se utilizan exclusivamente en la prueba de elección forzada y no se incorporan como negativos globales de la recuperación exacta.

3.3. Modelo, baselines y ablaciones

El modelo principal es OpenCLIP ViT-B-32 con pesos `laion2b_s34b_b79k`, utilizado sin ajuste fino. Los embeddings tienen 512 dimensiones y se normalizan con norma L2. Se implementaron dos baselines: un ranking aleatorio reproducible y un descriptor de histogramas HSV que utiliza solo la información cromática.

Las ablaciones comparan imágenes originales y grises, así como captions completos y captions sin color. La recuperación exacta mantiene una imagen relevante; la recuperación estructural utiliza 40 grupos textuales y siete imágenes relevantes por grupo.

4. Resultados

4.1. Recuperación exacta global

Cuadro 2: Recuperación exacta en una galería de 56 imágenes.

Método o condición	R@1	R@5	MRR	nDCG@10
Aleatorio	0,014	0,089	0,081	0,082
Histograma HSV	0,125	0,625	0,340	0,494
OpenCLIP	0,236	0,825	0,462	0,581
OpenCLIP, imagen gris	0,086	0,314	0,207	0,251

OpenCLIP supera descriptivamente a los dos baselines en las métricas principales. La diferencia de R@1 frente al histograma HSV es 0,111. No se realizaron pruebas de significancia para todas las comparaciones, por lo que las diferencias no se presentan como inferencia estadística.

Recuperación exacta en la galería global




Figura 1: Comparación de la recuperación exacta global.

4.2. Negativos difíciles

En las 56 unidades de elección forzada, el caption positivo ocupó el primer lugar en el 51,8 % de los casos. Este resultado supera el nivel de azar de 20 %, aunque muestra que el modelo falla en casi la mitad de las decisiones conjuntas.

Al considerar por separado las 224 comparaciones positivo–negativo, la tasa de victorias alcanza el 83,5 %. Los denominadores y las preguntas evaluadas son diferentes: la exactitud exige que el positivo supere simultáneamente a los cuatro negativos, mientras que la tasa pareada contabiliza cada enfrentamiento individual.

Cuadro 3: Resultados ante negativos difíciles.

Métrica	Valor	Interpretación
Exactitud	0,518	Positivo en primer lugar entre cinco candidatos.
MRR	0,729	Posición recíproca media del positivo.
nDCG@10	0,799	Calidad del ordenamiento local.
Tasa pareada	0,835	Pares en que el positivo supera al negativo.
Diferencia pareada media	0,026	Diferencia media de similitud.

Resultados por nivel de ambigüedad. El protocolo también conserva el nivel de ambigüedad asignado durante el diseño de cada patrón. Los resultados desagregados muestran diferencias entre los tres grupos:

Cuadro 4: Resultados de negativos difíciles por nivel de ambigüedad.

Ambigüedad	Consultas	Exactitud	MRR	nDCG@10
Alta	7	0,143	0,571	0,684
Baja	28	0,393	0,643	0,734
Media	21	0,810	0,897	0,923

El grupo de ambigüedad media presentó la mayor exactitud, mientras que el grupo alto obtuvo el menor resultado. Esta distribución no debe interpretarse como una relación general y monotónica entre ambigüedad y dificultad. El campo `ambiguity_level` es una etiqueta asignada durante el diseño del generador y no una medida empírica estimada a partir del comportamiento del modelo.

Además, los grupos tienen tamaños reducidos y desiguales, especialmente el nivel alto, que contiene solo siete consultas. Por ello, estos resultados se presentan como evidencia descriptiva interna del benchmark y no como una comparación estadísticamente concluyente.

Desempeño ante negativos difíciles




Figura 2: Desempeño ante negativos difíciles controlados.

4.3. Ablaciones cromáticas y recuperación estructural

La escala de grises reduce el R@1 exacto de 0,236 a 0,086. En la tarea estructural, la condición imagen gris y caption sin color obtiene Hit@1 de 0,425, pero la condición original conserva el mayor Hit@5, con 0,832. El resultado muestra un compromiso entre priorización inmediata y cobertura temprana.

Ablaciones cromáticas en la recuperación estructural




Figura 3: Ablaciones cromáticas en recuperación estructural multirrelevante.

4.4. Particiones sintéticas ID/OOD

Cuadro 5: Resultados descriptivos de OpenCLIP por partición sintética.

Partición	Consultas	R@1	R@5	MRR	nDCG@10
ID	150	0,233	0,880	0,478	0,599
OOD por paleta	60	0,233	0,933	0,478	0,606
OOD por patrón	50	0,140	0,540	0,337	0,452
OOD combinado	20	0,500	0,800	0,602	0,695

La caída más clara aparece en OOD por patrón. El valor alto de OOD combinado se basa en solo 20 consultas y no constituye evidencia de superioridad ni de generalización hacia textiles reales.

5. Análisis cualitativo y evaluación responsable

La evidencia cualitativa procede del protocolo histórico v1, que evaluó recuperación de imagen a texto sobre 40 imágenes y 200 captions. Se conserva porque permite examinar aciertos, errores, ambigüedad y confiabilidad, pero no constituye evidencia cuantitativa de los experimentos E1–E4 del benchmark v2.

5.1. Casos cualitativos heredados de v1

Se seleccionaron dos aciertos, dos errores y un caso ambiguo a partir de los rankings realmente producidos por el notebook. Los casos C01 y C02 situaron un caption correcto en la primera posición. En los errores C03 y C04, el primer caption correcto apareció en las posiciones 26 y 25, respectivamente. El caso C05 fue clasificado como ambiguo y ubicó el primer caption correcto en la cuarta posición.

Cuadro 6: Casos cualitativos del protocolo histórico v1.

Caso	Imagen	Tipo	Rango correcto
C01	T037	Acierto	1
C02	T032	Acierto	1
C03	T010	Error	26
C04	T040	Error	25
C05	T024	Ambiguo	4

Los aciertos muestran que el modelo puede recuperar captions compatibles cuando la composición, el patrón y la paleta presentan una correspondencia clara. Los errores C03 y C04 revelan un problema de alineamiento imagen–texto: el sistema prioriza descripciones plausibles, pero asociadas con otras imágenes visualmente próximas. Este es el error más relevante para un uso real, porque una salida aparentemente razonable podría interpretarse como correcta aunque la correspondencia exacta sea incorrecta.

El caso ambiguo recuerda que una única respuesta esperada puede resultar insuficiente cuando la imagen admite varias descripciones visualmente razonables. Por ello, el análisis cualitativo complementa las métricas de ranking, pero no debe utilizarse para modificar retrospectivamente el ground truth.

5.2. Pruebas de confiabilidad

El protocolo v1 estudió dos perturbaciones breves: reformulación textual y degradación visual. Cada prueba se aplicó a cinco casos.

Cuadro 7: Pruebas históricas de confiabilidad del protocolo v1.

Prueba	Casos	Cambio medio	Medio	Alto
Reformulación textual	5	2,60	3	1
Degradación visual	5	10,60	3	2

En la reformulación textual se registró además un cambio bajo; en la degradación visual no se observaron cambios bajos. La segunda perturbación produjo una variación de rango considerablemente mayor, lo que muestra sensibilidad a la pérdida de calidad visual. En conjunto, las diez observaciones registraron un cambio bajo, seis medios y tres altos. Estos resultados son exploratorios y no constituyen una certificación estadística de robustez.

La clasificación histórica del notebook fue *no confiable para uso real*. En consecuencia, el prototipo solo resulta admisible como herramienta exploratoria en condiciones académicas controladas, con supervisión humana y sin utilizar sus rankings como decisiones autónomas.

5.3. Explicabilidad basada en evidencia

La explicabilidad se documentó mediante un acierto y un error. En C01, la primera posición puede relacionarse con la coincidencia entre los atributos observables de la imagen y el caption recuperado, especialmente composición, motivo y paleta. En C03, el caption ubicado primero pertenece a otra imagen; este error sugiere que rasgos generales como geometría, repetición o color pudieron pesar más que la correspondencia específica.

Cuadro 8: Alcance de las explicaciones cualitativas.

Caso	Tipo	Evidencia utilizada	Límite de la explicación
C01	Acierto	Coincidencia de composición, motivo, paleta y posición del ranking.	No identifica qué regiones internas utilizó el modelo.
C03	Error	Caption incorrecto en primer lugar y caption correcto en rango 26.	No demuestra causalmente qué atributo originó la confusión.

Estas explicaciones se apoyan en atributos observables y en el ranking producido. No constituyen mapas de atención, atribuciones causales ni evidencia de comprensión del significado de los patrones. El reporte histórico utiliza precisamente C01 y C03 para documentar un acierto y un error, manteniendo explícitos estos límites.

5.4. Uso responsable

El uso recomendado se limita a docencia, análisis de recuperación multimodal, comparación de baselines y experimentación académica con supervisión humana. El principal riesgo consiste en interpretar una similitud visual como identificación confiable de una pieza.

El sistema no debe utilizarse para autenticación, atribución cultural o histórica, clasificación patrimonial, inferencia de procedencia, interpretación simbólica ni decisiones sobre textiles reales. Una afirmación irresponsable sería sostener que OpenCLIP comprende una cultura o reconoce la autenticidad de un objeto a partir de estos resultados sintéticos.

6. Discusión y amenazas a la validez

Los resultados muestran que OpenCLIP utiliza información adicional al color, pues supera al baseline HSV. Al mismo tiempo, la caída producida por la escala de grises demuestra que la paleta contribuye de forma importante a la identificación exacta. Cuando la relevancia se redefine por estructura, retirar el color puede favorecer algunas métricas, pero no todas; por ello, ninguna condición debe describirse como universalmente superior.

Las principales amenazas a la validez son el tamaño reducido del benchmark, la regularidad de las imágenes generadas, el vocabulario controlado, la presencia de atributos globalmente distintivos, el uso de un único modelo y la ausencia de pruebas inferenciales validadas para todas las comparaciones. Además, OOD describe la construcción interna del benchmark y no lo que OpenCLIP observó durante su preentrenamiento.

La especificación inicial contempló recuperación de imagen a texto. Durante la formalización del benchmark, la evaluación cuantitativa principal se consolidó como recuperación de texto a imagen, mientras que la evidencia histórica v1 conservó la dirección original. Esta diferencia se documenta para evitar mezclar protocolos y denominadores.

7. Reproducibilidad y trazabilidad

7.1. Entorno de ejecución

La ejecución canónica se realizó en Windows 10 con Python 3.11.9, PyTorch 2.13.0 en CPU, Torchvision 0.28.0 y OpenCLIP 3.3.0. El modelo evaluado fue OpenCLIP ViT-B-32 con pesos `laion2b_s34b_b79k`. Sus parámetros permanecieron congelados y los embeddings visuales y textuales tuvieron 512 dimensiones.

La semilla principal del experimento fue 225. Los embeddings fueron normalizados mediante norma L2 antes del cálculo de similitud. La auditoría del tokenizer procesó 600 textos, correspondientes a 280 captions completos, 40 captions estructurales sin color y 280 candidatos de la prueba de negativos difíciles, sin evidencia de truncamiento.

La configuración canónica utiliza CPU para reducir dependencias del hardware y facilitar la revisión del experimento. Esta decisión favorece la reproducibilidad computacional, aunque no garantiza identidad binaria de los resultados entre sistemas operativos, versiones de bibliotecas o arquitecturas diferentes.

7.2. Versión evaluada

La entrega final se encuentra asociada con el tag anotado `mcc225-examen-final-v2.1`. El tag apunta al commit del release auditado, mientras que un commit posterior integra ese mismo árbol en la rama `main`.

Cuadro 9: Identificadores de la entrega auditada.

Elemento	Identificador
Repositorio	https://github.com/hsancheza90-art/mcc225-textiles-generados-evaluacion-multimodal
Tag evaluado	<code>mcc225-examen-final-v2.1</code>
Commit del release	<code>5de136ca1fc438a0ec5425988dfab404a993eafe</code>
Integración final en <code>main</code>	<code>9a5a82d9f16f2eec84917de6f8e14097fc90e279</code>
SHA-256 del manifiesto	<code>acc26608cecb143588d4ad8239a954fe789ccc4fa0615711a140b9a46c6eda8</code>
SHA-256 del inventario	<code>394c91d35904650a8fb1cd7ed37bfa4632b79bd5899c4515f6b71277c7eb3b1f</code>

El manifiesto final registra 258 entradas inventariadas, agrupadas en 13 familias de artefactos. La entrega conserva 25 validadores contractuales, 18 resultados históricos protegidos y cinco figuras históricas protegidas. Estos controles permiten verificar que los resultados y la evidencia cualitativa no fueron modificados durante la preparación de la entrega.

7.3. Validación de los artefactos

Los resultados cuantitativos oficiales se encuentran bajo `results/v2/`. Las tablas utilizadas en este informe proceden de:

- `results/v2/tablas_maestras/metricas_maestras_v2.csv`;
- `results/v2/tablas_maestras/comparaciones_maestras_v2.csv`;
- `results/v2/tablas_maestras/resumen_tablas_maestras_v2.json`.

Con un entorno compatible ya activado, la validación principal puede ejecutarse desde la raíz del repositorio mediante:

```
python scripts/validar_config_informe_final_v2.py
python scripts/validar_tablas_maestras_v2.py
python scripts/validar_figuras_v2.py
python scripts/validar_informe_final_v2.py
python scripts/validar_manifiesto_entrega_v2.py
```

Los cuatro primeros comandos validan el contrato narrativo, las tablas maestras, las figuras y el informe canónico. El último comprueba la integridad de la entrega congelada y la correspondencia entre el manifiesto, el inventario y los archivos versionados.

La revisión no requiere ejecutar `generar_embeddings_v2.py` ni volver a descargar el modelo. Los embeddings y resultados oficiales permanecen congelados, por lo que las métricas, comparaciones y figuras pueden auditarse directamente desde los artefactos incluidos en el release.

7.4. Alcance de la reproducibilidad

El repositorio permite reconstruir la procedencia de cada cifra desde las configuraciones, embeddings, resultados de evaluación, tablas maestras y figuras. Esta trazabilidad corresponde a reproducibilidad computacional y auditabilidad del pipeline.

No se afirma reproducibilidad binaria entre equipos distintos, debido a posibles diferencias en bibliotecas numéricas, versiones del modelo, hardware y sistema operativo. Tampoco es necesario regenerar el dataset o los embeddings para verificar las conclusiones presentadas en este informe.

8. Conclusiones y trabajo futuro

8.1. Conclusiones

Este trabajo evaluó OpenCLIP ViT-B-32, sin ajuste fino y en régimen *zero-shot*, en una tarea controlada de recuperación de texto a imagen sobre 56 patrones textiles sintéticos. La evaluación utilizó 280 consultas textuales y distinguió tres protocolos con definiciones de relevancia diferentes: recuperación exacta, elección forzada ante negativos difíciles y recuperación estructural multirrelevante.

En la recuperación exacta, OpenCLIP obtuvo Recall@1 de 0,236, Recall@5 de 0,825, MRR de 0,462 y nDCG@10 de 0,581. Estos resultados fueron descriptivamente superiores tanto al baseline aleatorio como al histograma HSV. La diferencia respecto del baseline HSV indica que el modelo utiliza información adicional a la distribución global del color, aunque el experimento no permite afirmar que haya aprendido una representación composicional completa de todos los atributos.

El color contribuyó de forma importante a la identificación de la combinación exacta. Al convertir las imágenes a escala de grises, Recall@1 disminuyó de 0,236 a 0,086 y MRR de 0,462 a 0,207. Sin embargo, esta caída no implica que la estructura deje de ser útil. Cuando la relevancia se definió por patrón compartido, la condición con imagen gris y caption sin color obtuvo el mayor Hit@1, con 0,425, mientras que la condición original con caption completo conservó el mayor Hit@5, con 0,832. El resultado muestra un compromiso entre priorización inmediata y cobertura temprana, no una superioridad universal de una condición.

La evaluación con negativos difíciles mostró una discriminación local parcial. El caption positivo ocupó el primer lugar entre cinco candidatos en el 51,8 % de las 56 consultas, frente a un nivel de azar de 20 %. En las 224 comparaciones individuales positivo–negativo, la tasa de victorias fue 83,5 %. Esta diferencia muestra que el modelo suele superar a cada negativo por separado, pero todavía puede perder la primera posición cuando debe competir simultáneamente contra cuatro alternativas plausibles.

El análisis por partición identificó la mayor caída en el grupo OOD por patrón, con Recall@1 de 0,140 y MRR de 0,337. En cambio, OOD por paleta presentó resultados próximos a ID. El valor elevado de OOD combinado se obtuvo sobre solo 20 consultas, por lo que no constituye evidencia suficiente de mejor generalización. Estas particiones describen controles internos del benchmark y no permiten inferir qué patrones o paletas fueron observados durante el preentrenamiento de OpenCLIP.

En respuesta a la pregunta experimental, OpenCLIP puede recuperar una proporción relevante de las imágenes sintéticas correctas a partir de captions controlados y supera descriptivamente los baselines implementados. No obstante, su desempeño depende de señales cromáticas, presenta dificultades ante algunos cambios estructurales y no resuelve de manera consistente todos los negativos contrafactuales. Por ello, la evidencia respalda utilidad experimental dentro del benchmark, pero no demuestra comprensión cultural, autenticación patrimonial, identificación de procedencia ni generalización a textiles reales.

La evidencia histórica v1 refuerza esta cautela. Las pruebas breves de reformulación textual y degradación visual clasificaron el prototipo como no confiable para uso real. El sistema debe entenderse como una herramienta académica para estudiar recuperación multimodal, errores, ablaciones y baselines bajo condiciones controladas y con supervisión humana.

8.2. Trabajo futuro

El primer trabajo futuro consiste en ampliar el benchmark con más patrones, paletas, composiciones y generadores visuales. Esto permitiría reducir la influencia de regularidades propias de un único generador y construir particiones de prueba con mayor tamaño.

También resulta necesario evaluar captions menos reglados. Las consultas actuales utilizan un vocabulario controlado y cinco plantillas compartidas. Futuras evaluaciones deberían incorporar paráfrasis, sinónimos, variaciones gramaticales, omisiones de atributos y descripciones redactadas por personas, manteniendo un protocolo de anotación verificable.

Una tercera línea consiste en comparar distintas arquitecturas, tamaños de modelo y pesos preentrenados. El presente estudio utiliza un solo modelo OpenCLIP, por lo que no permite determinar si los resultados son específicos de ViT-B-32 o se mantienen en otros encoders visión–lenguaje.

La evaluación estadística también debe fortalecerse mediante intervalos de confianza, pruebas pareadas previamente especificadas y análisis de sensibilidad por patrón, atributo y nivel de ambigüedad. Estas extensiones deben definirse antes de observar los resultados y conservar la separación entre recuperación exacta, elección forzada y recuperación multirrelevante.

Finalmente, una eventual incorporación de textiles reales requeriría un nuevo protocolo metodológico y ético. Serían necesarios metadatos curatoriales, revisión especializada, documentación de procedencia, consentimiento cuando corresponda y una delimitación explícita de los usos permitidos. Los resultados del benchmark sintético no deben trasladarse directamente a objetos patrimoniales.

Referencias

Cherti, M., Beaumont, R., Wightman, R., Wortsman, M., Ilharco, G., Gordon, C., Schuhmann, C., Schmidt, L., & Jitsev, J. (2023). Reproducible Scaling Laws for Contrastive Language-Image Learning. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2818-2829. <https://doi.org/10.1109/CVPR52729.2023.00276>

- Järvelin, K., & Kekäläinen, J. (2002). Cumulated Gain-Based Evaluation of IR Techniques. *ACM Transactions on Information Systems*, 20(4), 422-446. <https://doi.org/10.1145/582415.582418>
- Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J., Krueger, G., & Sutskever, I. (2021). Learning Transferable Visual Models From Natural Language Supervision. *arXiv preprint arXiv:2103.00020*. <https://doi.org/10.48550/arXiv.2103.00020>


A. Trazabilidad de fuentes internas

Cuadro 10: Fuentes internas principales del informe.

Contenido	Artefacto del repositorio
Protocolo	docs/especificacion_experimental_v2.md
Dataset v1	docs/auditoria_dataset_v1.md
Patrones v2	docs/auditoria_visual_patrones_v2.md
Captions	docs/disenio_captions_positivos_v2.md
Negativos	docs/disenio_negativos_dificiles_v2.md
Entorno	docs/entorno_reproducible_v2.md
Métricas	results/v2/tablas_maestras/metricas_maestras_v2.csv
Comparaciones	results/v2/tablas_maestras/comparaciones_maestras_v2.csv
Informe canónico	reporte_evaluacion_responsable.md

B. Figuras complementarias

Efecto de la escala de grises en la recuperación exacta



Δ Margen positivo: -0.009

Fuente: tablas maestras auditables E1-E4, versión 2.

Figura 4: Efecto de la escala de grises en recuperación exacta.

Compromiso entre Hit@1 y Hit@5 estructurales





Figura 5: Compromiso entre Hit@1 y Hit@5 en recuperación estructural.

C. Evidencia cualitativa histórica

La Figura 6 presenta los dos aciertos, los dos errores y el caso ambiguo resumidos en el Cuadro 6. Estos resultados pertenecen al protocolo v1 de imagen a texto y no deben interpretarse como casos cuantitativos del benchmark v2.




C01 | T037 | acierto | rank correcto: 1

Salida modelo: Patron textil generado con composicion horizontal, motivos de bandas geometricas y paleta azul, crema, marron.

Esperado: Patron textil generado con composicion horizontal, motivos de bandas geometricas y paleta azul, crema, marron.

Comentario: El modelo ubicó un caption correcto en la primera posición. La salida coincide con atributos visibles como composición horizontal, motivo bandas geometricas y paleta azul_crema_marron.




C02 | T032 | acierto | rank correcto: 1

Salida modelo: Patron textil generado con composicion vertical, motivos de bandas geometricas y paleta azul, crema, marron.

Esperado: Patron textil generado con composicion vertical, motivos de bandas geometricas y paleta azul, crema, marron.

Comentario: El modelo ubicó un caption correcto en la primera posición. La salida coincide con atributos visibles como composición vertical, motivo bandas geometricas y paleta azul_crema_marron.




C03 | T010 | error | rank correcto: 26

Salida modelo: Patron textil generado con composicion horizontal, motivos de bandas geometricas y paleta multicolor, tierra.

Esperado: Diseno geometrico generado con paleta multicolor, tierra, estructura modular y repeticion visual.

Comentario: El modelo ubicó como primera opción un caption asociado a otra imagen. El primer caption correcto apareció en la posición 26. Esto sugiere una confusión entre patrones visualmente parecidos o una asociación insuficiente entre los atributos de la imagen y el texto correspondiente.




C04 | T040 | error | rank correcto: 25

Salida modelo: Patron textil generado con composicion horizontal, motivos de bandas geometricas y paleta multicolor, tierra.

Esperado: Diseno geometrico generado con paleta multicolor, tierra, estructura modular y repeticion visual.

Comentario: El modelo ubicó como primera opción un caption asociado a otra imagen. El primer caption correcto apareció en la posición 25. Esto sugiere una confusión entre patrones visualmente parecidos o una asociación insuficiente entre los atributos de la imagen y el texto correspondiente.



C05 | T024 | ambiguo | rank correcto: 4

Salida modelo: Patron textil generado con composicion horizontal, motivos de bandas geometricas y paleta blanco, negro, gris.

Esperado: Patron textil generado con composicion mixta, motivos de motivos geometricos combinados y paleta blanco, negro, gris.

Comentario: El caso se considera ambiguo porque la imagen presenta una lectura visual menos directa. El nivel de ambigüedad registrado es alto. La salida del modelo puede estar parcialmente relacionada con la imagen, pero no permite una decisión estricta sin revisión cualitativa.

Figura 6: Dos aciertos, dos errores y un caso ambiguo del protocolo v1.